

Classificação de Dados Planares com uma camada escondida

Bem-vindo a tarefa 3. Está na hora de construir a sua primeira rede neural, a qual conterá uma camada escondida. Você verá uma grande diferença entre este modelo e o modelo utilizando regressão logística.

Você irá aprender:

- Implementar uma rede neural para classificação entre 2 classes com uma única camada escondida
- Utilizar nós com uma função de ativação não-linear, como a tanh.
- Computar a função de perda utilizando entropia cruzada.
- Implementar propagação para frente e para trás.

1 - Pacotes

Primeiro vamos importar todos os pacotes que você irá utilizar nesta tarefa.

- [numpy](http://www.numpy.org) (www.numpy.org) é o pacote de computação científica do Python.
- [sklearn](http://scikit-learn.org/stable/) (<http://scikit-learn.org/stable/>) possui ferramentas simples e eficientes para data mining e análise de dados.
- [matplotlib](http://matplotlib.org) (<http://matplotlib.org>) é uma biblioteca para plotar gráficos em Python.
- `testCases` apresenta alguns exemplos de teste para verificar a implementação de funções.
- `planar_utils` apresenta várias funções úteis para esta tarefa.

```
In [3]: # Importar Pacotes
import numpy as np
import matplotlib.pyplot as plt
from testCases_v2 import *
import sklearn
import sklearn.datasets
import sklearn.linear_model
from planar_utils import plot_decision_boundary, sigmoid, load_planar_data, load_extra_datasets

%matplotlib inline

np.random.seed(1) # define um valor de semente para consistência dos resultados
```


2 - Base de dados

Primeiro vamos carregar a base de dados que será utilizada nesta tarefa. O código na célula abaixo irá carregar a "flor" uma base de dados com duas classes nas variáveis X e Y.

```
In [4]: X, Y = load_planar_dataset()
```

Visualize a base de dados utilizando a `matplotlib`. Os dados lembram uma "flor" com alguns pontos vermelhos (classificação $y=0$) e alguns pontos azuis ($y=1$). Sua tarefa é construir um modelo que se ajuste a estes dados.

```
In [5]: # Visualize os dados:
plt.scatter(X[0, :], X[1, :], c=Y[0, :], s=40, cmap=plt.cm.Spectral);
```



Você tem:

- um array (matrix) numpy, X, que contém os valores das características (x1, x2)
- um array (vetor) numpy, Y, que contém a classificação (vermelha:0, azul:1).

Vamos primeiro obter uma melhor noção sobre estes dados.

Exercício: Quantos exemplos de treinamento existem? Além disso, qual é o formato das variáveis X e Y?

Dica: Como você determina o formato de um array numpy? ([ajuda](https://docs.scipy.org/doc/numpy/reference/generated/numpy.ndarray.shape.html)) (<https://docs.scipy.org/doc/numpy/reference/generated/numpy.ndarray.shape.html>)

```
In [6]: ### INICIE O SEU CÓDIGO AQUI ### (~ 3 linhas de código)
shape_X = X.shape
shape_Y = Y.shape
m = X.shape[1]

# tamanho do conjunto de treinamento
### TÉRMINO DO CÓDIGO ###

print ('O formato de X é: ' + str(shape_X))
print ('O formato de Y é: ' + str(shape_Y))
print ('Existem m = %d exemplos no conjunto de treinamento!' % (m))

O formato de X é: (2, 400)
O formato de Y é: (1, 400)
Existem m = 400 exemplos no conjunto de treinamento!
```

Saída Esperada:

formato de X	(2, 400)
formato de Y	(1, 400)
m	400

3 - Regressão Logística Simples

Antes de construir uma rede neural completa, vamos primeiro ver como a regressão logística se sai neste problema. Você poderia utilizar a função pronta sklearn para fazer isto. Execute o código abaixo para treinar uma regressão logística com a base de dados.

```
In [7]: # Treinar um classificador com regressão logística
clf = sklearn.linear_model.LogisticRegressionCV();
clf.fit(X.T, Y.T);


/home/bruno/anaconda3/lib/python3.5/site-packages/sklearn/utils/validation.py:578: DataConversionWarning: A column-vector y was passed when a 1d array was expected. Please change the shape of y to (n_samples, ), for example using ravel().
  y = column_or_1d(y, warn=True)
```

É possível agora plotar a linha de decisão deste modelo executando o código abaixo.

```
In [8]: # Plotar a linha de decisão da regressão logística
plot_decision_boundary(lambda x: clf.predict(x), X, Y)
plt.title("Regressão Logística")

# Imprimir precisão
LR_predictions = clf.predict(X.T)
print ('A precisão da regressão logística é: %d ' % float((np.dot(Y,LR_predictions) + np.dot(1-Y,1-LR_predictions))/float(Y.size)*100) +
      '% ' + "(porcentagem de pontos classificados corretamente)")
```

A precisão da regressão logística é: 47 % (porcentagem de pontos classificados corretamente)



Saída Esperada:


Precisão	47%
---------------------	-----

Interpretação: O conjunto de dados não é linearmente separável, logo, regressão logística não vai apresentar um bom desempenho. Espera-se que a rede neural seja bem melhor. Vamos experimentar!

4 - Modelo de Rede Neural

Regressão logística não funcionou bem com a base de dados "flor". Vamos treinar uma Rede Neural com uma única camada escondida e ver como ela se sai.

Este é o modelo:



Matematicamente:

Para um exemplo $x^{(i)}$:

$$z^{[1](i)} = W^{[1]}x^{(i)} + b^{[1](i)} \quad (1)$$

$$a^{[1](i)} = \tanh(z^{[1](i)}) \quad (2)$$

$$z^{[2](i)} = W^{[2]}a^{[1](i)} + b^{[2](i)} \quad (3)$$

$$\hat{y}^{(i)} = a^{[2](i)} = \sigma(z^{[2](i)}) \quad (4)$$

$$y_{prediction}^{(i)} = \begin{cases} 1 & \text{if } a^{[2](i)} > 0.5 \\ 0 & \text{otherwise} \end{cases} \quad (5)$$

Dada a previsão sobre todos os exemplos é possível determinar o custo J da seguinte forma:

$$J = -\frac{1}{m} \sum_{i=0}^m \left(y^{(i)} \log(a^{[2](i)}) + (1 - y^{(i)}) \log(1 - a^{[2](i)}) \right) \quad (6)$$

Lembre-se: A metodologia geral para construir uma Rede Neural é:

1. Definir a estrutura da rede neural (# de nós de entrada, # de nós escondidos, etc).
2. Inicializar os parâmetros do modelo
3. Loop:
 - Implementar propagação para frente
 - Computar perda
 - Implementar propagação para trás e determinar os gradientes
 - Atualizar os parâmetros (gradiente descendente)

Geralmente se constroem funções auxiliares para computar as etapas 1-3 e então criamos uma função modelo composta das funções auxiliares que chamamos de `modelo_rn()`. Uma vez construído o modelo `modelo_rn()` e aprendido os parâmetros corretamente, é possível realizar previsões sobre dados novos.

4.1 - Definindo a estrutura de uma rede neural

Exercício: Defina três variáveis:

- `n_x`: o tamanho da camada de entrada
- `n_h`: o tamanho da camada escondida (ajuste este valor para 4)
- `n_y`: o tamanho da camada de saída

Dica: Use o formato de X e Y para encontrar `n_x` e `n_y`. Defina o tamanho da camada escondida como 4.

```
In [9]: # FUNÇÃO DE AVALIAÇÃO: Tamanho_Camadas

def Tamanho_Camadas(X, Y):
    """
    Argumentos:
    X -- dados de entrada no formato (tamanho da entrada, número de exem
plos)
    Y -- classificação no formato (tamanho da saída, número de exemplos)

    Retorna:
    n_x -- o tamanho da camada de entrada
    n_h -- o tamanho da camada escondida
    n_y -- o tamanho da camada de saída
    """
    ### INICIE O SEU CÓDIGO AQUI ### (≈ 3 linhas de código)
                                # tamanho da camada de entrada

    n_x = X.shape[0]
    n_h = 4
    n_y = Y.shape[0]

                                # tamanho da camada de saída

    ### TÉRMINO DO CÓDIGO ###
    return (n_x, n_h, n_y)
```

```
In [10]: X_assess, Y_assess = layer_sizes_test_case()
(n_x, n_h, n_y) = Tamanho_Camadas(X_assess, Y_assess)
print("O tamanho da camada de entrada é: n_x = " + str(n_x))
print("O tamanho da camada escondida é: n_h = " + str(n_h))
print("O tamanho da camada de saída é: n_y = " + str(n_y))

O tamanho da camada de entrada é: n_x = 5
O tamanho da camada escondida é: n_h = 4
O tamanho da camada de saída é: n_y = 2
```

Saida Esperada (estes não são os tamanhos que você irá utilizar na sua rede neural, eles foram utilizados aqui apenas para testar o seu código).

n_x	5
n_h	4
n_y	2

4.2 - Inicialização dos parâmetros do modelo

Exercício: Implemente a função `inicializar_parametros()`.

Instruções:

- Tenha a certeza de que o tamanho das matrizes/vetores de inicialização estão corretos. Reveja a rede neural da figura acima caso ache necessário.
- Inicialize as matrizes de peso com valores aleatórios.
 - Utilize: `np.random.randn(a,b) * 0.01` para criar uma matriz aleatória no formato (a,b).
- Inicialize o vetor de bias com zeros.
 - Utilize: `np.zeros((a,b))` para criar uma matriz de zeros no formato (a,b).

```
In [11]: # FUNÇÃO DE AVALIAÇÃO: inicializar_parametros

def inicializar_parametros(n_x, n_h, n_y):
    """
    Argumentos:
    n_x -- número de nós na camada de entrada
    n_h -- número de nós na camada escondida
    n_y -- número de nós na camada de saída

    Retorna:
    params -- um dicionário python contendo:
                W1 -- matriz de pesos no formato (n_h, n_x)
                b1 -- vetor bias no formato (n_h, 1)
                W2 -- matriz de pesos no formato (n_y, n_h)
                b2 -- vetor bias no formato (n_y, 1)
    """

    np.random.seed(2) # definimos a semente do gerador de números aleató-
    rios para comparar resultados.

    ### INICIE O SEU CÓDIGO AQUI ### (~ 4 linhas de código)
    W1 = np.random.randn(n_h, n_x) * 0.01
    b1 = np.zeros((n_h, 1))
    W2 = np.random.randn(n_y, n_h) * 0.01
    b2 = np.zeros((n_y, 1))
    ### TÉRMINO DO CÓDIGO ###
    # verifica os formatos do que foi gerado
    assert (W1.shape == (n_h, n_x))
    assert (b1.shape == (n_h, 1))
    assert (W2.shape == (n_y, n_h))
    assert (b2.shape == (n_y, 1))
    #cria o dicionário
    parameters = {"W1": W1,
                  "b1": b1,
                  "W2": W2,
                  "b2": b2}

    return parameters
```

```
In [30]: n_x, n_h, n_y = initialize_parameters_test_case()

parameters = inicializar_parametros(n_x, n_h, n_y)
print("W1 = " + str(parameters["W1"]))
print("b1 = " + str(parameters["b1"]))
print("W2 = " + str(parameters["W2"]))
print("b2 = " + str(parameters["b2"]))

W1 = [[-0.00416758 -0.00056267]
      [-0.02136196  0.01640271]
      [-0.01793436 -0.00841747]
      [ 0.00502881 -0.01245288]]
b1 = [[0.]
      [0.]
      [0.]
      [0.]]
W2 = [[-0.01057952 -0.00909008  0.00551454  0.02292208]]
b2 = [[0.]]
```

Saída Esperada:

W1	<code>[[-0.00416758 -0.00056267] [-0.02136196 0.01640271] [-0.01793436 -0.00841747] [0.00502881 -0.01245288]]</code>
b1	<code>[[0.] [0.] [0.] [0.]]</code>
W2	<code>[[-0.01057952 -0.00909008 0.00551454 0.02292208]]</code>
b2	<code>[[0.]]</code>

4.3 - O Loop

Exercício: Implemente `propagação_para_frente()`.

Instruções:

- Veja acima a representação matemática do seu classificador.
- Utilize a função `sigmoid()`. Ela está pré-definida (importada) neste notebook.
- Utilize a função `np.tanh()`. Ela faz parte da biblioteca `numpy`.
- Implemente as seguintes etapas:
 1. Recupere cada matriz/vetor de parâmetros do dicionário "parameters" (que é a saída da função `inicializar_parametros()`) usando `parameters["..."]`.
 2. Implemente a propagação para frente. Determine $Z^{[1]}$, $A^{[1]}$, $Z^{[2]}$ and $A^{[2]}$ (o vetor com todas as previsões sobre todos os exemplos do conjunto de treinamento).
- Os valores necessários para a propagação para trás serão armazenados na "cache". A cache será passada como entrada da função de propagação para trás.

```
In [12]: # FUNÇÃO DE AVALIAÇÃO: propagacao_para_frente

def propagacao_para_frente(X, parametros):
    """
    Argumentos:
    X -- dados de entrada no tamanho (n_x, m)
    parametros -- dicionário python contendo os parâmetros (saída da função de inicialização)

    Retorna:
    A2 -- a saída da função sigmoid da segunda ativação
    cache -- um dicionário contendo "Z1", "A1", "Z2" and "A2"
    """

    # Recupere cada parâmetro do dicionário de parametros
    ### INICIE O SEU CÓDIGO AQUI ### (~ 4 linhas de código)
    W1 = parametros["W1"]
    b1 = parametros["b1"]
    W2 = parametros["W2"]
    b2 = parametros["b2"]

    ### TÉRMINO DO CÓDIGO ###

    # Implemente a propagação para frente para calcular A2 (probabilidades)
    ### INICIE O SEU CÓDIGO AQUI ### (~ 4 linhas de código)
    Z1 = np.dot(W1, X) + b1
    A1 = np.tanh(Z1)
    Z2 = np.dot(W2, A1) + b2
    A2 = sigmoid(Z2)
    ### TÉRMINO DO CÓDIGO ###
    # verifica o formato de A2
    assert(A2.shape == (1, X.shape[1]))
    # cria o dicionário de saída
    cache = {"Z1": Z1,
            "A1": A1,
            "Z2": Z2,
            "A2": A2}

    return A2, cache
```

```
In [13]: X_assess, parametros = forward_propagation_test_case()
A2, cache = propagacao_para_frente(X_assess, parametros)
# Nota: neste caso é utilizada a média somente para garantir que as saídas são compatíveis.
print(np.mean(cache['Z1']), np.mean(cache['A1']), np.mean(cache['Z2']), np.mean(cache['A2']))

0.26281864019752443 0.09199904522700113 -1.3076660128732143 0.21287768171914198
```

Saída Esperada:

0.262818640198 0.091999045227 -1.30766601287 0.212877681719
--

Agora que você determinou o valor de $A^{[2]}$ (na variável "A2" do Python), que contém $a^{[2](i)}$ para cada exemplo, você pode determinar a função de custo da seguinte forma:

$$J = -\frac{1}{m} \sum_{i=0}^m (y^{(i)} \log(a^{[2](i)}) + (1 - y^{(i)}) \log(1 - a^{[2](i)})) \quad (13)$$

Exercício: Implemente `computar_custo()` para determinar o valor do custo J .

Instruções:

- Existem diversas formas de se implementar a perda por entropia cruzada. Para ajudá-lo, mostramos abaixo como ela poderia ser implementada. $-\sum_{i=0}^m y^{(i)} \log(a^{[2](i)})$:

```
logprobs = np.multiply(np.log(A2), Y)
cost = - np.sum(logprobs)           # não é necessário fazer um loop
!
```

(você pode utilizar tanto o `np.multiply()` e então `np.sum()` ou diretamente `np.dot()`).

```
In [14]: # FUNÇÃO DE AVALIAÇÃO: computar_custo

def computar_custo(A2, Y, parametros):
    """
    Computa o custo por entropia cruzada mostrado na equação (13)

    Argumentos:
    A2 -- 0 valor de saída da segunda ativação no formato (1, número de
    exemplos)
    Y -- vetor de classificação real no formato (1, número de exemplos)
    parametros -- dicionário python contendo os parâmetros W1, b1, W2 e
    b2

    Retorna:
    custot -- o custo por entropia cruzada de acordo com a equação (13)
    """

    m = Y.shape[1] # número de exemplos

    # Computação do custo por entropia cruzada
    ### INICIE O SEU CÓDIGO AQUI ### (≈ 2 linhas de código)

    cost = (-1 / m) * np.sum((Y * np.log(A2)) + ((1 - Y) * (np.log(1 - A
    2))))

    ### TÉRMINO DO CÓDIGO ###

    cost = np.squeeze(cost)      # verifique que as dimensões estão corre
    tas.                          # por exemplo, transforme [[17]] em 17
    assert(isinstance(cost, float))

    return cost
```

```
In [15]: A2, Y_assess, parameters = compute_cost_test_case()

print("custo = " + str(computar_custo(A2, Y_assess, parameters)))

custo = 0.6930587610394646
```

Saída Esperada:

custo	0.693058761...
------------------	----------------

Usando a cache computada durante a propagação para frente, é possível determinar a propagação para trás.

Exercício: Implemente a função `propagacao_para_tras()`.

Instruções: A propagação para trás geralmente é a mais difícil de ser implementada em deep learning por ser mais matemática. Para ajudá-lo mostramos abaixo a propagação para trás. Você deve utilizar as seis equações mostradas no lado direito pois estamos utilizando vetorização.

Summary of gradient descent

$dz^{[2]} = a^{[2]} - y$	$dZ^{[2]} = A^{[2]} - Y$
$dW^{[2]} = dz^{[2]} a^{[1]T}$	$dW^{[2]} = \frac{1}{m} dZ^{[2]} A^{[1]T}$
$db^{[2]} = dz^{[2]}$	$db^{[2]} = \frac{1}{m} np.sum(dZ^{[2]}, axis = 1, keepdims = True)$
$dz^{[1]} = W^{[2]T} dz^{[2]} * g^{[1]'}(z^{[1]})$	$dZ^{[1]} = W^{[2]T} dZ^{[2]} * g^{[1]'}(Z^{[1]})$
$dW^{[1]} = dz^{[1]} x^T$	$dW^{[1]} = \frac{1}{m} dZ^{[1]} X^T$
$db^{[1]} = dz^{[1]}$	$db^{[1]} = \frac{1}{m} np.sum(dZ^{[1]}, axis = 1, keepdims = True)$

Andrew Ng

- Dicas:

- Para computar $dZ^{[1]}$ você precisa computar $g^{[1]'}(Z^{[1]})$. Como $g^{[1]}(.)$ é a função de ativação tanh, se $a = g^{[1]}(z)$ então $g^{[1]'}(z) = 1 - a^2$. E você pode determinar $g^{[1]'}(Z^{[1]})$ usando `(1 - np.power(A1, 2))`.

```

In [28]: # FUNÇÃO DE AVALIAÇÃO: propagação_para_tras

def propagacao_para_tras(parametros, cache, X, Y):
    """
    Implemente a propagação para trás usando as instruções acima.

    Argumentos:
    parametros -- dicionário python contendo os parâmetros
    cache -- um dicionário contendo "Z1", "A1", "Z2" e "A2".
    X -- dados de entrada no formato (2, numero de exemplos)
    Y -- vetor com a classificação correta de cada exemplo no formato (1
    , numero de exemplos)

    Retorna:
    grads -- um dicionário python contendo os gradientes com relação a c
    ada parâmetro
    """
    m = X.shape[1]

    # 1) recupere as metrizas W1 e W2 dos parametros.
    ### INICIE O SEU CÓDIGO AQUI ### (~ 2 linhas de código)
    W1 = parametros['W1']
    W2 = parametros['W2']

    ### TÉRMINO DO CÓDIGO ###

    # 2) recupere A1 e A2 do dicionario cache.
    ### INICIE O SEU CÓDIGO AQUI ### (~ 2 linhas de código)
    A1 = cache['A1']
    A2 = cache['A2']

    ### TÉRMINO DO CÓDIGO ###

    # Propagacao para tras: determine dW1, db1, dW2, db2.
    ### INICIE O SEU CÓDIGO AQUI ### (~ 6 linhas de código, corresonden
    do às 6 equações acima)
    dZ2 = A2 - Y
    dW2 = np.dot((1 / m), np.dot(dZ2, A1.T))
    db2 = np.dot((1 / m), np.sum(dZ2, axis=1, keepdims=True))
    dZ1 = np.dot(W2.T, dZ2) * (1 - np.power(A1, 2))
    dW1 = np.dot((1 / m), np.dot(dZ1, X.T))
    db1 = np.dot((1 / m), np.sum(dZ1, axis=1, keepdims=True))
    ### TÉRMINO DO CÓDIGO ###

    grads = {"dW1": dW1,
             "db1": db1,
             "dW2": dW2,
             "db2": db2}

    return grads

```

```
In [29]: parameters, cache, X_assess, Y_assess = backward_propagation_test_case()

grads = propagacao_para_tras(parameters, cache, X_assess, Y_assess)
print ("dW1 = "+ str(grads["dW1"]))
print ("db1 = "+ str(grads["db1"]))
print ("dW2 = "+ str(grads["dW2"]))
print ("db2 = "+ str(grads["db2"]))

dW1 = [[ 0.00301023 -0.00747267]
 [ 0.00257968 -0.00641288]
 [-0.00156892  0.003893  ]
 [-0.00652037  0.01618243]]
db1 = [[ 0.00176201]
 [ 0.00150995]
 [-0.00091736]
 [-0.00381422]]
dW2 = [[ 0.00078841  0.01765429 -0.00084166 -0.01022527]]
db2 = [[ -0.16655712]]
```



Saída Esperada:

dW1	[[0.00301023 -0.00747267] [0.00257968 -0.00641288] [-0.00156892 0.003893] [-0.00652037 0.01618243]]
db1	[[0.00176201] [0.00150995] [-0.00091736] [-0.00381422]]
dW2	[[0.00078841 0.01765429 -0.00084166 -0.01022527]]
db2	[[-0.16655712]]

Exercício: Implemente a regra para atualizar os parâmetros. Use gradiente descendente. Você deve utilizar (dW1, db1, dW2, db2) para atualizar (W1, b1, W2, b2).

Regra Geral do Gradiente Descendente: $\theta = \theta - \alpha \frac{\partial J}{\partial \theta}$ onde α é a taxa de aprendizado e θ representa um parâmetro.

Ilustração: O algoritmo de gradiente descendente com uma boa taxa de de aprendizado (convergendo) e uma taxa de aprendizado ruim (divergendo). Imagens, cortesia de Adam Harley.



```
In [38]: # FUNÇÃO DE AVALIAÇÃO: atualizar_parametros

def atualizar_parametros(parametros, grads, learning_rate = 1.2):
    """
    Atualizacao de parametros utilizando a regra de gradiente descendente
    e dada acima.

    Argumentos:
    parametros -- dicionario python contendo os parametros.
    grads -- dicionario python contendo os gradientes.

    Retorna:
    parametros -- dicionario python contendo os valores de atualizacao dos
    parametros.
    """
    # 1) recupere cada parametro do dicionario parametros
    ### INICIE O SEU CÓDIGO AQUI ### (~ 4 linhas de código)
    W1 = parametros["W1"]
    b1 = parametros["b1"]
    W2 = parametros["W2"]
    b2 = parametros["b2"]

    ### TÉRMINO DO CÓDIGO ###

    # 2) Recupere cada gradiente do dicionario grads
    ### INICIE O SEU CÓDIGO AQUI ### (~ 4 linhas de código)
    dW1 = grads["dW1"]
    db1 = grads["db1"]
    dW2 = grads["dW2"]
    db2 = grads["db2"]
    ## TÉRMINO DO CÓDIGO ###

    # 3) regra de atualizacao para cada parametro
    ### INICIE O SEU CÓDIGO AQUI ### (~ 4 linhas de código)
    W1 = W1 - learning_rate * dW1
    b1 = b1 - learning_rate * db1
    W2 = W2 - learning_rate * dW2
    b2 = b2 - learning_rate * db2
    ### TÉRMINO DO CÓDIGO ###

    parametros = {"W1": W1,
                  "b1": b1,
                  "W2": W2,
                  "b2": b2}

    return parametros
```

```
In [39]: parameters, grads = update_parameters_test_case()
parameters = atualizar_parametros(parameters, grads)

print("W1 = " + str(parameters["W1"]))
print("b1 = " + str(parameters["b1"]))
print("W2 = " + str(parameters["W2"]))
print("b2 = " + str(parameters["b2"]))

W1 = [[-0.00643025  0.01936718]
      [-0.02410458  0.03978052]
      [-0.01653973 -0.02096177]
      [ 0.01046864 -0.05990141]]
b1 = [[-1.02420756e-06]
      [ 1.27373948e-05]
      [ 8.32996807e-07]
      [-3.20136836e-06]]
W2 = [[-0.01041081 -0.04463285  0.01758031  0.04747113]]
b2 = [[0.00010457]]
```

Saída Esperada:

W1	[[[-0.00643025 0.01936718] [-0.02410458 0.03978052] [-0.01653973 -0.02096177] [0.01046864 -0.05990141]]
b1	[[[-1.02420756e-06] [1.27373948e-05] [8.32996807e-07] [-3.20136836e-06]]
W2	[[[-0.01041081 -0.04463285 0.01758031 0.04747113]]
b2	[[[0.00010457]]

4.4 - Integrar as partes 4.1, 4.2 e 4.3 no modelo_rn()

Exercício: Construa o modelo de rede neural `modelo_rn()`.

Instruções: O modelo de rede neural deve utilizar as funções definidas previamente na ordem correta.

```

In [45]: # FUNÇÃO DE AVALIAÇÃO: modelo_rn

def modelo_rn(X, Y, n_h, num_iterations = 10000, print_cost=False):
    """
    Argumentos:
    X -- dados de entrada no formato (2, numero de exemplos)
    Y -- classificação correta no formato (1, numero de exemplos)
    n_h -- tamanho da camada escondida (número de nós)
    num_iterations -- Número de interações no loop do gradiente descendente

    print_cost -- se True, imprime o valor do custo a cada 1000 interações

    Retorna:
    parametros -- parametros aprendidos pelo modelo. Eles podem ser utilizados para prever saídas em entradas novas.
    """

    np.random.seed(3)
    n_x = Tamanho_Camadas(X, Y)[0]
    n_y = Tamanho_Camadas(X, Y)[2]

    # Inicializacao de parametros, então, recupere W1, b1, W2, b2. Entradas: "n_x, n_h, n_y". Saídas = "W1, b1, W2, b2, # parametros".
    ### INICIE O SEU CÓDIGO AQUI ### (~ 5 linhas de código)
    parametros = inicializar_parametros(n_x, n_h, n_y)
    W1 = parametros["W1"]
    b1 = parametros["b1"]
    W2 = parametros["W2"]
    b2 = parametros["b2"]

    ### TÉRMINO DO CÓDIGO ###

    # Loop (gradiente descendente)

    for i in range(0, num_iterations):

        ### INICIE O SEU CÓDIGO AQUI ### (~ 4 linhas de código)
        # propagacao para frente. Entradas: "X, parametros". Saídas: "A2, cache".
        A2, cache = propagacao_para_frente(X, parametros)

        # funcao de custo. Entradas: "A2, Y, parametros". Saída: "custo".
        custo = computar_custo(A2, Y, parametros)

        # propagacao para trás. Entradas: "parametros, cache, X, Y". Saídas: "grads".
        grads = propagacao_para_tras(parametros, cache, X, Y)

        # Atualizacao dos parametros utilizando Gradiente descendente. Entradas: "parametros, grads". Saída: "parametros".
        parametros = atualizar_parametros(parametros, grads)

        ### TÉRMINO DO CÓDIGO ###

        # Imprimir o custo a cada 1000 interações
        if print_cost and i % 1000 == 0:
            print ("Custo após interação %i: %f" %(i, custo))

    return parametros

```



```
In [46]: X_assess, Y_assess = nn_model_test_case()
parameters = modelo_rn(X_assess, Y_assess, 4, num_iterations=10000, print_cost=True)
print("W1 = " + str(parameters["W1"]))
print("b1 = " + str(parameters["b1"]))
print("W2 = " + str(parameters["W2"]))
print("b2 = " + str(parameters["b2"]))
```

```
Custo após interação 0: 0.692739
Custo após interação 1000: 0.000218
Custo após interação 2000: 0.000107
Custo após interação 3000: 0.000071
Custo após interação 4000: 0.000053
Custo após interação 5000: 0.000042
Custo após interação 6000: 0.000035
Custo após interação 7000: 0.000030
Custo após interação 8000: 0.000026
Custo após interação 9000: 0.000023
W1 = [[-0.65848169  1.21866811]
      [-0.76204273  1.39377573]
      [ 0.5792005   -1.10397703]
      [ 0.76773391  -1.41477129]]
b1 = [[ 0.287592 ]
      [ 0.3511264 ]
      [-0.2431246 ]
      [-0.35772805]]
W2 = [[-2.45566237 -3.27042274  2.00784958  3.36773273]]
b2 = [[0.20459656]]
```

Saída Esperada:

custo após a interação 0	0.692739
:	:
W1	[[[-0.65848169 1.21866811] [-0.76204273 1.39377573] [0.5792005 -1.10397703] [0.76773391 -1.41477129]]
b1	[[[0.287592] [0.3511264] [-0.2431246] [-0.35772805]]
W2	[[[-2.45566237 -3.27042274 2.00784958 3.36773273]]
b2	[[[0.20459656]]

4.5 Prevendo

Exercício: Use o seu modelo para prever saídas de novas entradas utilizando `prever()`. Use a propagação para frente para prever os resultados.

Lembre-se: $\text{prever} = y_{\text{previsto}} = \mathbb{1}\{\text{ativação} > 0.5\} = \begin{cases} 1 & \text{se ativação} > 0.5 \\ 0 & \text{caso contrário} \end{cases}$

Como exemplo, se você ajustar as entradas de uma matriz X para 0 e 1 baseado no "threshold" você faria: $X_{\text{new}} = (X > \text{threshold})$

```
In [78]: # FUNÇÃO DE AVALIAÇÃO: prever

def prever(parametros, X):
    """
    Utilizando os parâmetros aprendidos, prever uma classe para cada ex
    mplo na entrada X.

    Argumentos:
    parâmetros -- dicionário python contendo seus parâmetros
    X -- Dados de entrada no formato (n_x, m)

    Retorna
    previsoes -- vetor de previsões paa nosso modelo (vermelho: 0 / azul
    : 1)
    """

    # Computa as probabilidades usando propagação para frente, e classif
    ica em 0/1 usando 0.5 como threshold.
    ### INICIE O SEU CÓDIGO AQUI ### (~ 2 linhas de código)
    A2, cache = propagacao_para_frente(X, parametros)
    X_new = (A2 > 0.5)
    ### TÉRMINO DO CÓDIGO ###

    return X_new
```

```
In [79]: parameters, X_assess = predict_test_case()

predictions = prever(parameters, X_assess)
print("média prevista = " + str(np.mean(predictions)))

média prevista = 0.6666666666666666
```

Saída Esperada:

média prevista	0.666666666667
--------------------	----------------


Está na hora de executar o seu modelo e ver como ele desempenha em um conjunto de dados planares. Execute o código a seguir para testar seu modelo com uma única camada escondida contendo n_h nós.

```
In [80]: # Construa um modelo com n_h nós na camada escondida
parametros = modelo_rn(X, Y, n_h = 4, num_iterations = 10000, print_cost
= True)

# Plotar a borda de limites no plano
plot_decision_boundary(lambda x: prever(parametros, x.T), X, Y)
plt.title("Borda de decisão para uma camada escondida de tamanho " + str
(4))
```

```
Custo após interação 0: 0.693048
Custo após interação 1000: 0.288083
Custo após interação 2000: 0.254385
Custo após interação 3000: 0.233864
Custo após interação 4000: 0.226792
Custo após interação 5000: 0.222644
Custo após interação 6000: 0.219731
Custo após interação 7000: 0.217504
Custo após interação 8000: 0.219471
Custo após interação 9000: 0.218612
```

```
Out[80]: Text(0.5,1,'Borda de decisão para uma camada escondida de tamanho 4')
```



Saída Esperada:

Custo após interação 9000	0.218607
-------------------------------	----------

```
In [81]: # Print accuracy
predictions = prever(parametros, X)
print ('Precisao: %d' % float((np.dot(Y,predictions.T) + np.dot(1-Y,1-pr
edictions.T))/float(Y.size)*100) + '%')
```

```
Precisao: 90%
```

Saída Esperada:

Precisão	90%
--------------	-----

A precisão está realmente alta se comparada com a regressão logística. O modelo aprendeu o padrão das pétalas da flor! Redes neurais são capazes de aprender limites de decisão altamente não-lineares, diferente de a regressão logística.

Vamos tentar diferentes números de nós na camada escondida.

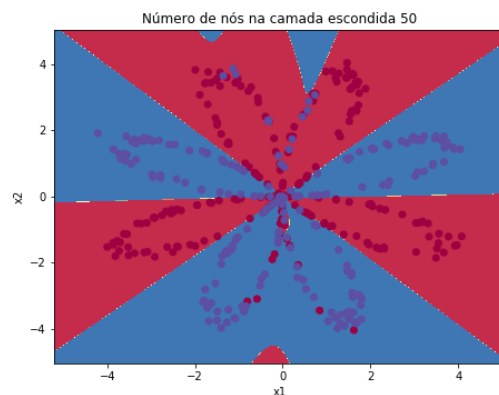


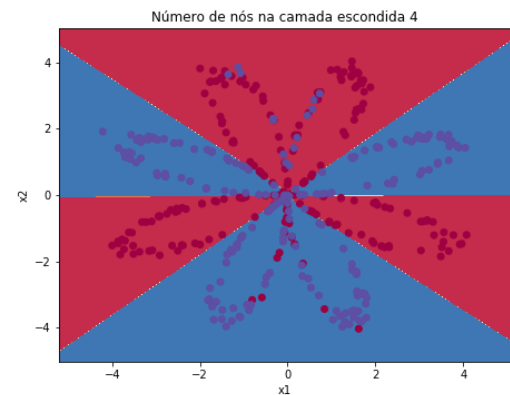

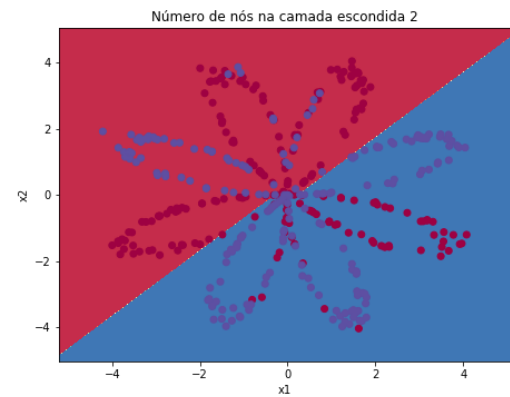

4.6 - Ajustando o número de nós na camada escondida (opcional)

Execute o código abaixo. Ele deve levar entre 2 e 3 minutos. Você deve observar ao final comportamentos diferentes do modelo, dependendo do número de nós na camada escondida.

```
In [82]: # Isto pode levar uns 2 minutos para ser executado

plt.figure(figsize=(16, 32))
hidden_layer_sizes = [1, 2, 3, 4, 5, 20, 50]
for i, n_h in enumerate(hidden_layer_sizes):
    plt.subplot(5, 2, i+1)
    plt.title('Número de nós na camada escondida %d' % n_h)
    parameters = modelo_rn(X, Y, n_h, num_iterations = 5000)
    plot_decision_boundary(lambda x: prever(parameters, x.T), X, Y)
    predictions = prever(parameters, X)
    accuracy = float((np.dot(Y,predictions.T) + np.dot(1-Y,1-predictions
.T))/float(Y.size)*100)
    print ("Precisão para {} nós escondidos: {} %".format(n_h, accuracy)
)
```

Precisão para 1 nós escondidos: 67.5 %
Precisão para 2 nós escondidos: 67.25 %
Precisão para 3 nós escondidos: 90.75 %
Precisão para 4 nós escondidos: 90.5 %
Precisão para 5 nós escondidos: 91.25 %
Precisão para 20 nós escondidos: 90.0 %
Precisão para 50 nós escondidos: 90.75 %



Interpretação:

- Quanto maior o modelo (com mais nós escondidos) mais fácil é o ajuste no conjunto de treinamento, até que, eventualmente, os modelos maiores se sobreajustam aos dados.
- O melhor número de nós na camada escondida parece ser algo em torno de $n_h = 5$. Neste caso, a rede se ajusta aos dados e não apresenta sobreajuste.
- Mais para frente vamos falar sobre regularização, que ajuda a utilizar modelos grandes (com $n_h = 50$) sem que ocorra o sobreajuste.

Exercício opcional:

Nota: Lembre-se de salvar a tarefa e criar uma cópia para executar os exercícios opcionais.

Alguns exercícios opcionais que você pode explorar para entender melhor as redes neurais:

- O que ocorre se trocamos a função de ativação da tanh para a sigmoid ou a ReLu?
- Como o modelo se comporta se alteramos a taxa de aprendizado?
- O que ocorre se modificamos o conjunto de dados? (Veja a part 5 abaixo)

Você Aprendeu:

- Construir uma rede neural completa com camada escondida.
- Utilizar nós com comportamento não linear.
- Implementar a propagação para frente e para trás e treinar uma rede neural.
- Ver o impacto no modelo ao variar o número de nós na camada escondida, incluindo o sobreajuste.

5) Desempenho em outras bases de dados

Se quiser você pode rodar novamente o notebook todo (exceto a parte do conjunto de dados) para cada uma das bases de dados abaixo.

```
In [90]: # Bases de dados
noisy_circles, noisy_moons, blobs, gaussian_quantiles, no_structure = load_extra_datasets()


datasets = {"noisy_circles": noisy_circles,
            "noisy_moons": noisy_moons,
            "blobs": blobs,
            "gaussian_quantiles": gaussian_quantiles}

### INICIE O SEU CÓDIGO AQUI ### (escolha a sua base de dados)
dataset = "gaussian_quantiles"
### TÉRMINO DO CÓDIGO ###

X, Y = datasets[dataset]
X, Y = X.T, Y.reshape(1, Y.shape[0])

# fazer blobs binários
if dataset == "blobs":
    Y = Y%2

# Visualizar os dados
plt.scatter(X[0, :], X[1, :], c=Y[0,:], s=40, cmap=plt.cm.Spectral);
```



Parabéns, você completou esta tarefa!

Referências:

- <http://scs.ryerson.ca/~aharley/neural-networks/> (<http://scs.ryerson.ca/~aharley/neural-networks/>)
- <http://cs231n.github.io/neural-networks-case-study/> (<http://cs231n.github.io/neural-networks-case-study/>)